# Optimiser son utilisation d'Unix

## Bernard TATIN

bernard.tatin@outlook.fr

RÉSUMÉ. Ce document vient des tréfonds de l'espace temps. Il a débuté il y a bien plus de trois ans de cela, repris de manière plus systématique et se trouve fortement complété aujourd'hui.

La première partie rappelle (rapidement) l'histoire et les concepts principaux des SHELLS. La deuxième partie est très orientée sur la recherche de qui a piraté $ma\ machine$ mais peut être d'une grande utilité pour les débutants. La troisième partie, quant à elle, se focalise sur les scripts. Une quatrième partie donnera des notions des outils indispensables pour utiliser correctement son système UNIX.

Ce document (en pleine réorganisation) et ses sources en LATEX sont disponibles sur GitHub.

Première partie - a. l'histoire et les concepts	2
- a.1. Une histoire d' <b>Unix</b>	2
- a.2. Les shells	3
- a.2.1. Le fonctionnement	5
- a.2.2. Quelques shells célèbres	5
- $a.2.2.1.$ sh, le Bourne shell	5
- $a.2.2.2.$ csh, le C shell	5
- a.2.2.3. tcsh ou le csh interactif	6
- $a.2.2.4.$ ksh, le Korn Shell	6
- $a.2.2.5.$ zsh, le Z SHELL	6
- a.2.2.6. bash, Bourne Again SHELL	6
Deuxième partie - b. la configuration et la ligne de commande	7
- b.1. La configuration	7
- b.1.1. Le shell personnel	7
- b.1.2. Configurer le prompt	7
- b.2. La ligne de commande	9
1	

- b.2.1. Les boucles	9
- b.2.1.1. La boucle <b>for</b>	9
- b.2.1.2. La boucle <b>while</b>	10
- b.2.2. Surprises avec stat, find et xargs	10
- b.2.2.1. stat	10
- b.2.2.2. Réfléchissons un peu	11
- b.2.2.3. Tous les fichiers du monde	12
- b.2.2.4. Application pratique	13
- b.2.3. Les surprises de <b>sudo</b>	15
- $b.2.4$ . <b>POSIX</b> et <b>GNU</b>	17
Troisième partie - c. les scripts et les exemples	17
- c.1. Les scripts shell	17
- c.1.1. Structure des scripts	18
- c.1.2. Choisir son Shell	19
- c.1.3. Les paramètres des scripts	19
- c.1.4. Tests et boucles	19
- $c.1.5$ . Conditions, valeurs de retour des programmes	20
- c.1.6. Redirections et tubes (ou pipes)	20
- c.2. Exemples de manipulation de texte	21
- c.2.1. Des stats	21
- c.2.2. Peut-on faire mieux?	23
- c.2.2.1. Les options	23
- c.2.2.2. Avec <b>bash</b>	28
Quatrième partie - d. commandes utiles	30
- d.1. les noms de fichiers	30
- d.2. cherche et remplace	31
- d.2.1. cherche	31

Table des matières

# Première partie - a. l'histoire et les concepts

# - a.1. Une histoire d'Unix

Voici une (rapide) histoire d' $\mathbf{Unix}$ , choisie parmi d'autres, parmi celles qui évoluent avec le temps autant parce que des personnages hauts en couleur et ayant réussi à voler la vedette à de plus modestes collègues se font effacer eux-même par de plus

brillants qu'eux, soit parce que, vieillissant ils se laissent aller à des confidences inattendues.

En nous basant sur Brève histoire d'**Unix**, on rappelle que  $AT\mathcal{E}T$  travaillait à la fin des années 60, sur un système d'exploitation **Multics** qui devait révolutionner l'histoire de l'informatique. Si révolution il y eut, ce fut dans les esprits : de nombreux concepts de ce système ont influencés ses successeurs, dont **Unix**. Ken Thompson et Dennis Ritchie des fameux  $Bell\ Labs$  et qui travaillaient (sans grande conviction, semble-t-il) sur **Multics**, décidèrent de lancer leur propre projet d'OS :

baptisé initialement UNICS (UNiplexed Information and Computing Service) jeu de mot avec "eunuchs' (eunuque) pour "un Multics emasculé", par clin d'æil au projet Multics, qu'ils jugeaient beaucoup trop compliqué. Le nom fut ensuite modifié en Unix <sup>1</sup>.

L'essor d'Unix est très fortement lié à un langage de programmation, le C. À l'origine, le premier Unix était écrit en assembleur, puis Ken Thompson crée un nouveau langage, le B. En 1971, Dennis Ritchie écrit à son tour un nouveau langage, fondé sur le B, le C. Dès 1973, presque tout Unix est réécrit en C. Ceci fait probablement d'Unix le premier système au monde écrit dans un langage portable, c'est-à-dire autre chose que de l'assembleur<sup>2</sup>.

Ce que j'ai surtout retenu de tout cela, c'est qu'**Unix** a banalisé autant l'utilisation des stations de travail connectées en réseau que le concept de *shell*, des système de fichiers hiérarchisés, des périphériques considérés comme de simples fichiers, concepts repris (et certainement améliorés) à **Multics** comme à d'autres. Pour moi, la plus grande invention d'**Unix**, c'est le langage C qui permet l'écriture des systèmes d'exploitations et des logiciels d'une manière très portable. N'oublions pas qu'aujourd'hui encore, C (mais pas C++) est un des langages les plus portable, même s'il commence à être concurrencé par Java par exemple.

#### - a.2. Les shells

Un SHELL est une *coquille*, pour reprendre la traduction littérale, autour du système d'exploitation. Voici un magnifique diagramme (d'après ce que l'on trouve sur le WEB comme dans d'anciens ouvrages) donnant une idée du concept :

<sup>1.</sup> cf. l'article Multics de Wikipedia

<sup>2.</sup> cf. Brève histoire d'UNIX




FIGURE 1. shell **Unix** Source: le WEB, ouvrages divers

Entre mes débuts dans le monde de l'informatique et aujourd'hui, le concept de SHELL a quelque peu évolué. Certains qualifient l'explorateur de Windows comme un SHELL. Ont-ils raison? Certainement si l'on se réfère à l'image précédente : nos commandes (clique, clique et reclique) envoyée au shell graphique sont transmises au noyau qui nous renvoie, par l'intermédiaire du

shell graphique, de belles images. Il faut dire que l'explorateur Windows est le premier contact que l'utilisateur a avec sa machine. Et sur l'article interface système de Wikipedia, on trouve cette définition :

Une interface système, SHELL en anglais, est une couche logicielle qui fournit l'interface utilisateur d'un système d'exploitation. Il correspond à la couche la plus externe de ce dernier.

#### Ce même article cite les:

shells graphiques fournissant une interface graphique pour l'utilisateur (GUI, pour Graphical User Interface)

Dans le monde Unix, le concept de Shell reste plus modeste, même si Midnight Commander (mc) est parfois considéré comme un Shell :

Pour nous et dans tout ce qui suit, nous considérons comme SHELL :

un interpréteur de commandes destiné aux systèmes d'exploitation Unix et de type Unix qui permet d'accéder aux fonctionnalités internes du système d'exploitation. Il se présente sous la forme d'une interface en ligne de commande accessible depuis la console ou un terminal. L'utilisateur lance des commandes sous forme d'une entrée texte exécutée ensuite par le SHELL. Dans les différents systèmes Windows, le programme



FIGURE 2. mc dans une session Cygwin

Source: mon PC

analogue est command.com  $\Omega H$ cmd.exe .

cf. SHELL UNIX sur Wikipedia

- a.2.1. Le fonctionnement. Le fonctionnement général est assez simple, surtout si l'on ne tient pas compte de la gestion des erreurs comme dans le graphique suivant qui peut être appliqué à tout bon interpréteur. Seuls les détails de process command et execute command vont réellement changer.

L'exécution d'un programme suit l'algorithme:

À noter que la commande **exec** se comporte différemment : elle correspond à l'appel système **exec** .

#### - a.2.2. Quelques SHELLS célèbres.

- a.2.2.1. sh , le Bourne SHELL. L'ancêtre, toujours vivant et avec lequel sont écrits une grande majorité des scripts actuels. Son intérêt essentiel est justement l'écriture de scripts. Pour l'interaction, il est absolument nul mais bien utile parfois pour dépanner.
- a.2.2.2. csh ,  $le\ C$  SHELL. Il se voulait le remplaçant glorieux de l'ancêtre sh avec une syntaxe considérée plus lisible car proche du C. Il est de plus en plus abandonné y compris par ses admirateurs les plus fervents, vieillissants dans la solitude la plus complète. Essayez d'écrire un script

execute

FIGURE 3. SHELL: fonctionnement général Source: créé avec yEd

en csh d'un peu d'envergure sans faire de copié/collé! Il n'y a en effet pas de possibilité de créer des fonctions et, ce qui gêne peut-être encore plus les administrateurs système, il n'y a pas de gestion d'exception. Cependant, il fût certainement le premier à proposer l'historique des commandes.

A noter qu'il fût crée par Bill Joy, l'un des fondateurs historiques de la société Sun Microsystems.

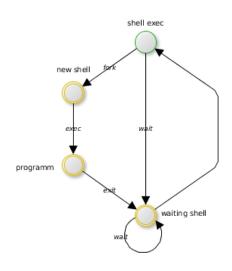


FIGURE 4. SHELL : exécution d'un programme Source: créé avec yEd

- a.2.2.3. tcsh ou le csh interactif. Le pendant interactif du précédent. Il lui reste des afficionados qui aiment bien sa gestion de l'historique et de la ligne de commande. Il est une extension de csh, i.e.tout ce qui peut-être fait par csh est fait par tcsh. Sur de nombreux systèmes (Mac OS X entre autre), ces deux SHELLs pointent sur le même exécutable (avec un lien symbolique).

En séquence *nostalgie*, je me souviens que c'est ce SHELL interactif que j'utilisais sur mon premier **Unix**, en 87/88.

- a.2.2.4. ksh ,  $le\ Korn$  Shell. Initialement écrit pour **Unix** par David Korn au début des années 80, ce Shell a été repris par Microsoft pour Windows. Compatible

avec sh, il propose de nombreuses avancées comme beaucoup de fonctionnalités de tcsh, des fonctions, des exceptions, des manipulations très évoluées de chaînes de caractères, ...

- a.2.2.5. zsh ,  $le\ Z$  SHELL. C'est mon préféré pour l'interactivité, la complétion et bien d'autres choses encore dont il est capable depuis sa création ou presque. Comme ksh, il est compilable en bytecode et propose des bibliothèques thématiques comme la couleur, les sockets, la gestion des dates...
- a.2.2.6. bash, Bourne Again SHELL. C'est le descendant le plus direct de sh. C'est certainement le SHELL le plus répandu dans le monde Linux aujour-d'hui.

Lors de ma découverte de Linux, je l'ai vite abandonné car il était très en retard pour la complétion en ligne de commande par rapport à d'autres, y compris tcsh qui commençait pourtant à vieillir un peu. Il a fallu beaucoup d'années (pratiquement 10) pour qu'il en vienne à peu près au niveau de zsh.

Aujourd'hui, c'est le shell par défaut de nombreuses distributions Linux et il commence à devenir très utilisé comme shell de script par défaut.

# Deuxième partie - b. la configuration et la ligne de commande

# - b.1. La configuration

- **b.1.1.** Le shell personnel. La première des configuration est le choix de son shell par défaut sur son compte personnel. C'est très simple :

1 chsh

Aidons-nous du manuel (sous **NetBSD**):

- b.1.2. Configurer le prompt. Sur ma machine virtuelle **NetBSD**, j'obtiens quelque chose comme ceci :

Le prompt, ce sont les caractères colorés que l'on voit en début de chaque lignes de commande. Ce prompt m'a aidé, voire sauvé plusieurs fois. Celui-ci m'affiche le nom de l'utilisateur courant en bleu, de la machine en blanc et du répertoire courant en blanc et gras. Lorsque j'ai des sessions sur plusieurs machines, je vois tout de suite où je me trouve avec son nom. Ensuite, lorsque je me déplace de répertoires en répertoires, je n'ai pas besoin de faire d'éternels **pwd** pour savoir où je me trouve. En plus, lorsque je trouve dans un dépôt SVN, j'ai un affichage me donnant les indi-

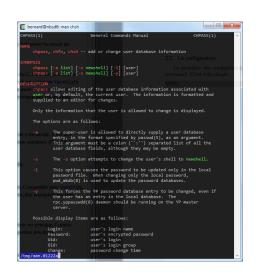


FIGURE 5. man chsh sous NETBSD

Source: ma machine virtuelle

cations sur le répertoire de travail (on ne peut pas le faire sous Cygwin) :



FIGURE 6. un prompt sous **NETBSD**, avec zsh

Source: ma machine virtuelle

Pour finir, le nom de l'utilisateur change de couleur lorsque je suis en **root** :

Tous les shells interactifs de ma connaissance ont au moins un fichier de configuration exécuté au lancement : avec zsh, c'est .zhrc, avec bash, c'est .bashrc et avec csh, c'est .cshrc. Aussi loin que mes souvenirs remontent, on personnalise le prompt avec la variable PS1 et ce, même pour le MS/DOS.

### Voici un hexdump de mon **PS1** :

```
1 00000000
25 7b 1b 5b 30 31 3b 33 31 6d 25
7d 25 28 3f 2e |%{.[01;31m%}%(?.]
2 00000010
2e 25 3f 25 31 76 20 29 25 7b 1
b 5b 33 37 6d 25 |.%?%1v )%{.[37m%]
3 0000020
7d 25 7b 1b 5b 33 34 6d 25 7d 25
6e 25 7b 1b 5b |}%{.[34m%}%n%{.[]
4 0000030
30 30 6d 25 7d 40 25 6d 20 25 34
30 3c 2e 2e 2e |00m%}@%m %40<...|
5 00000040
3c 25 42 25 7e 25 62 25 3c 3c 20
24 7b 56 43 53 |<%B%~%b%<< ${VCS}|
```

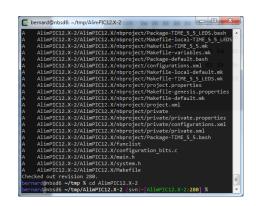


FIGURE 7. dans un répertoire de travail SVN, avec zsh

Source: ma machine

```
6 00000050

5f 49 4e 46 4f 5f 6d 65 73 73 61

67 65 5f 30 5f |_INFO_message_0_|

7 00000060 7d 25 23 20 0a

|}%# ./

8 00000065
```

# - b.2. La ligne de commande

Pour de multiples raisons déjà plus ou moins évoquées plus haut, j'ai choisi de travailler avec zsh comme shell par défaut. C'est ce que nous allons faire ici, autant sous FreeBSD que sous Linux, tout simplement pour prouver que l'utilisation du shell est assez indépendante du système sous-jacent. Mais comme je sais que certains systèmes viennent avec bash ou tcsh, sans possibilité de modification, je les évoqueraient donc, en particulier tcsh qui est utilisé très souvent, avec csh, pour l'administration. Ce n'est que fortuitement que j'examinerais ksh, autant par manque d'habitude que parce que je ne l'ai jamais rencontré.

# - b.2.1. Les boucles. Il y a while et for .

- b.2.1.1. La boucle for . On commence par celle-ci car elle en a dérouté plus d'un. Nous avons, avec zsh et bash, deux syntaxes essentielles. La première parcourt un ensemble de données :

```
for file_name in *.txt
do
cat $file_name
done
```

FIGURE 8. en root avec zsh Source: ma machine

Il y a la boucle plus classique pour les spécialistes de Java :

```
1 for ((i=5; i< 8; i++))
2 do
3    echo $i
4 done</pre>
```

Avec tcsh, nous aurons:

```
foreach file_name (*.txt)

cat $file_name

end

foreach i ('seq 5 1 8')

echo $i

end
```

- b.2.1.2. La boucle while . Elle permet de boucles infinies comme celle-ci avec zsh , bash et ksh :

```
while true; do date ``+%T''; sleep 1; done
```

Avec tcsh, nous écrirons en deux lignes:

```
while (1); date ``+%T''; sleep 1;
end
```

# - b.2.2. Surprises avec stat, find et xargs.

- b.2.2.1. stat . La commande stat permet de connaître bon nombre de détails à propos d'un fichier comme ici :

```
bernard@debian7 ~ % stat *
2 install:
3 device 70
4 inode 1837064
5 mode
          16877
6 nlink 3
7 uid 1000
8 gid 1000
9 rdev 7337007
10 size 512
11 atime 1383862259
12 mtime 1383085660
13 ctime 1383085660
14 blksize 16384
15 blocks 4
16 link
17
18 userstart.tar.gz:
19 device 70
```

```
inode
            1837156
20
21
   mode
            33188
   nlink
22
   uid
            1000
23
            1000
24
   gid
25
   rdev
            7371584
   size
            3498854
   atime
            1383855566
27
   mtime
            1383855552
29
   ctime
            1383855552
   blksize 16384
30
   blocks
            6880
31
   link
32
```

On obtient, sous zsh, un résultat totalement identique sous **NetrBSD** et sous **Linux**. Si l'on fait un **which stat**, nous obtenons, sur les deux systèmes, le message **stat**: **shell built-in command**. C'est ce qui me plait sous zsh, les commandes non standard comme **stat** sont remplacées par des fonctions dont le résultat ne réserve pas de surprise. Si je veux une sortie plus agréable et n'afficher que la date de dernière modification (cf. The zsh/stat module pour de plus amples explications):

```
bernard@debian7 ~ % stat -F "%Y-%m-%d %T" +mtime -n *
install 2013-10-29 23:27:40

userstart.tar.gz 2013-11-07 21:19:12

bernard@debian7 ~ %

bernard@NBSD-64bits ~ % stat -F "%Y-%m-%d %T" +mtime -n *
install 2013-11-14 09:52:56

userstart.tar.gz 2013-11-08 00:54:06

bernard@NBSD-64bits ~ %
```

- b.2.2.2.  $Réfléchissons\ un\ peu$ . Grâce à zsh, nous avons une méthode extrêmement portable entre Unix pour afficher des données détaillées des fichiers. Pour l'exemple, prenons le stat d'origine :

```
bernard@debian7 ~ % /usr/bin/stat --printf="%n %z\n" *
install 2013-10-29 23:27:40.000000000 +0100

userstart.tar.gz 2013-11-07 21:19:12.000000000 +0100

bernard@debian7 ~ %
```

```
bernard@NBSD-64bits ~ % /usr/bin/stat -t "%Y-%m-%d %T" -f "%Sc %N" *
2 2013-11-14 09:52:56 install
3 2013-11-08 00:54:06 userstart.tar.gz
4 bernard@NBSD-64bits ~ %
```

- b.2.2.3. Tous les fichiers du monde. Si je veux faire la même chose que précédemment, mais sur tous les fichiers de la machine, on peut tomber sur ce message d'erreur :

```
bernard@debian7 ~ % stat -F "%Y-%m-%d %T" +ctime -n $(find / -name "*
    ")
zsh: liste d'arguments trop longue: stat
bernard@debian7 ~ %
```

C'est là que **xargs** entre en jeu, mais avec un nouveau problème :

La commande xargs va chercher non pas la fonction de zsh mais le binaire qui se trouve sur le PATH de la machine. On doit donc faire :

#### Sous NetBSD:

```
5 ./.zshrc.private~ 2013-11-08 01:13:05
6 ./.viminfo 2013-11-08 01:14:38
7 ./.xinitrc 2013-11-08 01:14:44
8 ./.Xauthority 2013-11-08 01:16:25
9 bernard@NBSD-64bits ~
```

- b.2.2.4. Application pratique. Sur le serveur, qui est sous **Linux**, faisons la même chose ou presque, on place la date en premier et c'est la surprise du jour :

En rajoutant l'option **-print0** à **find**, l'option **-0** à **xargs**, nous obtenons le bon résultat :

```
[bigserver] (689) ~ % find /etc -name
                                        "*" -print0 | xargs -0
      --printf="%z %n\n" | sort
2
3 2013-11-12 10:51:42.041176453 +0100 /etc/php5/conf.d/ldap.ini
4 2013-11-12 10:55:05.017425662 +0100 /etc/php5/cgi
  2013-11-12 10:55:05.017425662 +0100 /etc/php5/cgi/php.ini
  2013-11-13 14:55:28.001191244 +0100 /etc/apache2/sites-available/
      aenercom.preprod.conf
  2013-11-13 14:56:35.601352228 +0100 /etc/apache2/sites-available/
      device.sigrenea.conf
  2013-11-13 14:56:35.601352228 +0100 /etc/apache2/sites-enabled
9 2013-11-13 17:16:04.377217037 +0100 /etc/apache2/sites-available
10 2013-11-13 17:16:04.377217037 +0100 /etc/phpmyadmin
11 2013-11-14 01:03:38.589252417 +0100 /etc/php5/conf.d/mysqli.ini
2013-11-14 01:05:14.997350491 +0100 /etc/php5/conf.d
  2013-11-14 01:05:14.997350491 +0100 /etc/php5/conf.d/mcrypt.ini
```

En fait, les noms de fichier sous **Unix** peuvent contenir beaucoup de caractères étranges en dehors de / . **xargs** prend le caractère **LF** comme fin d'enregistrement de la part de son entrée standard. Si jamais un fichier contient ce caractère, plus rien ne va. Les nouvelles options permettent à **find** d'utiliser **0x00** comme séparateur d'enregistrement et à **xargs** de bien l'interpréter.

Il y a aussi une autre explication, depuis bien longtemps les outils **GNU** fonctionnent comme ceci et ce n'est que très récemment que le couple **find** /**xargs** fonctionne ainsi.

Après toutes ces considérations, on constate que le 14 Novembre 2013, un peu après 1 heure du matin, quelqu'un a modifié les fichiers /etc/php5/conf.d/mysqli.ini et /etc/php5/conf.d/mcrypt.ini , tout simplement pour remplacer les commentaires de type shell par des commentaires de type fichier ini.

Après une attaque du serveur, il est intéressant de faire le même exercice sur les répertoires vitaux comme **/bin**. Pour éviter des listings trop important, on limite la sortie à l'année 2013 et on fait une jolie boucle :

```
1 [bigserver] (694) ~ % for d in /bin /sbin /lib /lib32 /usr/bin /usr/
        sbin /usr/lib /usr/lib32; do
2 find $d -name "*" -print0 | xargs -0 stat --printf="%z %n\n" |
        egrep "^2013"
3 done | sort
```

Nous obtenons un listing fort long, correspondant aux mises à jour faites le 8 et le 12 Novembre. Maintenant que nous savons que l'attaque a eu lieu avant le 8 Novembre, on sélectionne plus sévèrement :

```
1 [bigserver] (695) ~ % for d in /bin /sbin /lib /lib32 /usr/bin /usr/
        sbin /usr/lib /usr/lib32; do
2 find $d -name "*" -print0 | xargs -0 stat --printf="%z %n\n" |
        egrep "^2013-11-0[1-7]"
3 done | sort
4 [bigserver] (696) ~ %
```

Cependant, rien ne prouve que nous n'avons pas eu de désordres un peu avant ou un peu pendant. Comme le gros des fichiers est dans /usr/lib, éliminons le de la liste :

Nous n'avons des modifications qu'entre le 8 et le 12 Novembre.

Plus fort encore, afficher les fichiers modifiés ce jour :

On est débordé par l'affichage des fichiers système de Linux. Pour palier à cet inconvénient, on demande à **find** d'abandonner les répertoire **/sys** et **/proc** .

- b.2.3. Les surprises de sudo . Reprenons l'exemple précédent en redirigeant la sortie standard vers /dev/null :

On aura une sortie comme celle-ci :

```
find: "/var/lib/postgresql/9.1/main": Permission non accordee
find: "/var/lib/sudo": Permission non accordee
find: "/var/cache/ldconfig": Permission non accordee
find: "/var/log/exim4": Permission non accordee
find: "/var/log/apache2": Permission non accordee
...
```

Pour éliminer les **find: ... Permission non accordee**, on utilise **sudo** .

```
sudo find / \( -path /proc -o -path /sys \) -prune -o -name "*" -
    print0 | xargs -0 stat --printf="%z %n\n" | egrep "^$(date '+%Y-%
    m-%d')" > /dev/null
```

#### C'est pire:

Nous avons demandé à **sudo** de traité **find** et avec le *pipe*, nous demandons à **xargs** de traiter les lignes de sorties avec **stat**. Ce dernier récupère un nom de fichier et le traite comme tel mais comme il n'est pas lancé avec **sudo**, nous avons ces erreurs. Essayons ceci :

C'est pas mieux, autant sous Linux que sous NetBSD:

```
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
sudo: unable to execute /usr/bin/stat: Argument list too long
```

Il faut bien l'avouer, je ne sais pas quoi dire de plus ici - sinon noter un TODO: comprendre ce qui ce passe. Ce qui est bien avec  $\mathbf{Unix}$ , c'est qu'il y a toujours un moyen de s'en sortir. On remarquera quelques différences entre les mondes  $\mathbf{Linux}$  et  $\mathbf{BSD}$ , en particulier avec  $\mathbf{man}$   $\mathbf{sh}$ , où le premier nous renvoie sur  $\mathbf{bash}$  alors que le second traite bien directement de  $\mathbf{sh}$ . Dans tous les cas,  $\mathbf{sudo}$   $\mathbf{sh}$   $-\mathbf{c}$ 

Et sous Linux:

- b.2.4. POSIX et GNU. Profitons d'un moment de calme pour remarquer que de nombreuses commandes se comportent de manière très standard entre différents systèmes, y compris parfois, sous MS/DOS. Tout cela vient de POSIX ou de GNU.

Les guerres de religions qui opposent parfois violemment les mondes **BSD** et **Linux**, les supporters de **Vi** et **Emacs**, ... finissent par être absorbées avec le temps et seuls quelques irréductibles les raniment, souvent plus pour s'exposer aux yeux (blasés maintenant) du petit monde concerné. Seule reste l'opposition farouche entre tenants du libre et leurs opposants.

Ici, nous avons utilisé **find** de la même manière sous **Linux** et sous **NetBSD** ce qui n'a pas été toujours le cas, de même, sh se comporte de manière identique à quelques octets près sur les deux systèmes, ce qui n'était pas forcément vrai il y a quelques années. Pour revenir à **find**, nous avions un paquet de compatibilité **GNU** disponible sur plusieurs **BSD** qui reprenait le **find** que nous connaissons maintenant et l'on pouvait différencier **gfind** de **bsdfind** <sup>3</sup>.

# Troisième partie -c. les scripts et les exemples

#### - c.1. Les scripts shell

La magie des SHELLSest infinie, ils nous permettent en effet de créer des programmes complets, complexes... parfois aux limites du lisible. On les appelle scripts

<sup>3.</sup> A vérifier dans les détails.

pour les opposer aux applications généralement créées à partir de langages compilés mais cela ne devrait rien changer au fait qu'ils doivent être conçus avec un soin égal à celui apporté aux autres langages comme C/C++, Java...

Dans tout ce qui suit, il ne faut pas perdre de vue que le SHELLest une *coquille* entourant le noyau d'**Unix**. Certains aspects des SHELLSne font que recouvrir des appels systèmes.

- c.1.1. Structure des scripts. Ce qui est décrit ici est valable autant pour des langages interprétés comme l'horrible Perl<sup>4</sup>, le sublime Scheme<sup>5</sup>, le célèbre Python que pour n'importe quel shell.

La première ligne d'un script est le *shebang*. Cette ligne est très importante car elle indique de manière sûre quel interpréteur il doit utiliser pour exécuter le corps du script. Voici quelques exemples :

sh:: #!/bin/sh

bash: : #!/bin/sh

Perl: : #!/usr/bin/env perl

Python 2.7: : #!/usr/bin/env python2.7

Python: : #!/usr/bin/env python

awk::#!/bin/awk -f

Les deux caractères #! sont considérés comme un nombre magique par le système d'exploitation qui comprend immédiatement qu'il doit utiliser le script dont le nom et les arguments suivent les deux caractères.

Dans un Shellinteractif, l'exécution d'un script suit l'algorithme suivant :

```
fork ();
if (child) {
   open(script);

switch(magic_number) {
   case 0x7f'ELF':
       exec_binaire();

break;

case '\#!':
   load_shell(first_line);
```

<sup>4.</sup> je ne suis pas objectif, mais quand même...

<sup>5.</sup> là, je me sens plus objectif...ou presque.

- c.1.2. Choisir son SHELL. Par tradition autant que par prudence, on écrit ses scripts SHELLpour le SHELLd'origine, soit sh. Par prudence car on est certain qu'il sera présent sur la machine même si elle démarre en mode dégradé. Cependant, beaucoup de scripts sont applicatifs et ne pourront pas fonctionner en mode dégradé. Autant se servir d'un SHELLplus complet comme bash.
- c.1.3. Les paramètres des scripts. Les paramètres, leur nombre et leur taille n'ont de limites que de l'ordre de la dizaine de Ko. Il faut donc pouvoir y accéder. Le paramètre \$0 est le nom du script parfois avec le nom du répertoire. Les neufs suivants sont nommés \$1, ..., \$9. Pour accéder aux autres il faut ruser un peu avec l'instruction  $\verb|shift|$ .
  - c.1.4. Tests et boucles. Les tests se font avec if de cette manière :

```
1 if condition
2 then
3 ...
4 else
5 ...
6 fi
```

Dans le même ordre d'idée, nous avons le while :

```
while condition
do
do
done
```

La construction des **condition** est tout un art, d'autant plus qu'en lieu et place du **if** nous pouvons écrire :

```
ou bien:

condition && condition_true && ...

ou bien:

condition || condition_false
```

Nous avons aussi une boucle for :

```
for index in ensemble
do
do
done
```

La détermination de **ensemble** est assez naturelle comme par exemple avec **\$(1s \*.java)**. Mais il faut être prudent : selon les Shellsles résultats peuvent différer.

- c.1.5. Conditions, valeurs de retour des programmes. Tout les programmes sous Unix s'achèvent par un return EXIT\_CODE ou bien un exit (EXIT\_CODE) bien senti. La valeur EXIT\_CODE est renvoyée au programme appelant, notre SHELL. On peut le récupérer depuis la variable \$#? puis étudier le cas :

```
myprogram arg1 arg2 ...
   case \$\#? in
        0)
3
             its-okayyy
4
5
             ;;
6
        1)
             bad_parameterzzz
8
             ;;
9
        2 | 3 | 4)
             cant-open-filezzz
10
11
12
             unknow-error
13
14
```

UNIX considère que la valeur de retour o est signe que tout va bien et que tout autre valeur exprime une condition d'erreur. On peut donc utiliser cette propriété ainsi :

```
1 myprogram arg1 arg2 ... || onerror ``Error code \$\#?''
```

- c.1.6. Redirections et tubes (ou *pipes*). Le premier piège dans l'utilisation des tubes dans un scripts est simple : pour chaque tube, on crée un nouveau processus. Ainsi le script suivant ne renvoie pas le résultat escompté :

```
#!/bin/sh

compteur=0

ls -1 /bin | while read line; do
    compteur=$(( compteur + 1 ))

done

printf "Il y a %d fichiers dans /bin\n" ${compteur}

1 $ ./badl.sh

Il y a 0 fichiers dans /bin
```

La variable compteur fait partie de l'environnement de **bad1.sh** . Lorsque la boucle **while** se lance, elle est dans un nouveau contexte et sa modification se perd à la fin de la boucle. On corrige de cette manière :

```
#!/bin/sh
2
3
  compteur=0
4
  ls -l /bin > /tmp/ls-l.tmp
5
  while read line; do
6
       compteur=$((compteur + 1))
  done < /tmp/ls-l.tmp</pre>
8
9
  printf "Il y a %d fichiers dans /bin\n" ${compteur}
10
  $ ./not-so-bad1.sh
2 Il y a 173 fichiers dans /bin
```

# - c.2. Exemples de manipulation de texte

- c.2.1. Des stats. Voici un extrait d'un fichier /var/log/messages

```
Nov 3 10:16:19 localhost org.gnome.zeitgeist.SimpleIndexer[2637]: **
    \ldots
Nov 3 10:16:34 localhost org.freedesktop.FileManager1[2637]:
    Initializing \ldots
Nov 3 10:16:34 localhost nautilus: [N-A] Nautilus-Actions Menu
    Extender 3.2\ldots
```

Nous voulons déterminer les moments les plus actifs de ce fichier avec une granularité de une heure. La manipulation est simple :

```
afficher le fichier: cat file-name,
découper le ficher: cut -d':'-f1,
trier le fichier: sort,
compter les occurences: uniq -c,
trier en décroissant: sort -n.
```

Ce qui nous donne la commande :

```
cat $file-name |
cut -d ':' -f 1 |
sort |
uniq -c |
sort -n
```

On obtient rapidement un script (stat1.sh) à partir de cette ligne de commande :

```
#!/bin/sh
2
  scriptname="$(basename $0)"
3
4
   dohelp() {
       cat << DOHELP</pre>
6
  \{scriptname\} [-h|--help] : this text
  ${scriptname} file file\ldots : stats
   DOHELP
9
10
       exit 0
11
   [ $# -eq 0 ] && dohelp
14 case $1 in
       -h | --help)
     dohelp
```

### On peut tester:

```
$ ./stat1.sh messages-1 /var/log/messages /var/log/messages.1
     152 Nov
3
     155 Oct 27
4
     156 Oct 28
5
     164 Oct 28 17
6
7
     186 Oct 25 14
     213 Oct 28 11
8
     216 Nov
               3 10
9
     260 Oct 28 10
10
11
     636 Oct 26 15
     774 Oct 28 07
12
    1770 Nov
               3
13
                 09
    3844 Oct 28 14
14
   26201 Oct 28 15
```

- c.2.2. Peut-on faire mieux? Bien sûr! On peut avoir d'autres options que la simple aide, on peut aussi gérer correctement les erreurs, les signaux Unix...
- c.2.2.1. Les options. Depuis longtemps il existe une norme **POSIX** permettant de gérer les options de la ligne de commande. Malheureusement, il fut une époque où la norme avait beaucoup de variantes ce qui m'a poussé à faire ma propre gestion de ces paramètres.

Voici ma méthode, facile à mémoriser mais pas parfaite et un peu lourde :

l'aide: créer une fonction *dohelp* comme dans l'exemple précédent; le nom *dohelp* permet d'éviter un clash avec une éventuelle commande *help*.

s'assurer de l'existence de paramètres: il suffit de faire le test [ \$# -eq 0 ] et exécuter le code nécessaire.

vider la liste des paramètres: une boucle while [ \$# -ne 0 ] fait l'affaire.

Voici un exemple plus parlant (script **stat2.sh**):

```
#!/bin/sh
2
   scriptname="$(basename $0)"
4
   dohelp() {
       cat << DOHELP</pre>
   ${scriptname} [-h|--help] : this text
   ${scriptname} [options] file file...: stats
   options:
       -s|--size N: number of most important hours, default 5
       -b|--byhour : for each hours
   DOHELP
12
       exit 0
13
14
15
16 \text{ size=} 5
17 byhour="cut -d ':' -f 1"
18 is_byhour=0
   after=""
19
20
21
   set_size() {
       [ "$1" -lt 1 ] && onerror 3 "size must be > 1"
22
23
       size=$1
24
   set_byhour() {
25
       byhour="${byhour} | tr -s ' ' | cut -d ' ' -f 3"
26
       after=" | sort -k 2"
27
       is_byhour=1
28
       set_size 24
29
31
   doit() {
32
       end=1
       cmd="cat $0 | ${byhour} | sort | uniq -c | sort -nr | head -n ${
           size} ${after}"
    case ${is_byhour} in
```

```
35
                printf "%-7.7s %-6.6s %-2.2s\n" "occurences" "date" "hour
36
                printf "%-17.17s\n" "-----
37
38
39
          1)
                printf "%-7.7s %-2.2s\n" "occurences" "hour"
40
                printf "%-10.10s\n" "----
41
42
43
       esac
       eval "${cmd}"
44
45
46
47
   [ $# -eq 0 ] && dohelp
48
49
   while [ $end -eq 0 ]
50
51
       case $1 in
52
            -h | --help)
53
                dohelp
54
55
            -s | --size)
56
                shift
57
                [ $# -eq 0 ] && onerror 2 "$1 needs a parameter"
58
                set_size "$1"
59
                shift
60
61
          -b | --byhour)
62
                shift
63
                set_byhour
64
                ;;
66
         *)
                doit "$@"
67
68
                ;;
69
       esac
   done
```

Et maintenant avec le **getopts** <sup>6</sup>:

1 #!/bin/sh

<sup>6.</sup> soyez prudents avec les (très) anciennes versions de Red Hat

```
3 scriptname=$(basename $0)
4
5 dohelp() {
6 cat << DOHELP
7 ${scriptname} [-h] : this text
8 ${scriptname} [options] file file\ldots : stats
9 options:
      -s N : number of most important hours, default 5
      -b : for each hours
12 DOHELP
      exit 0
13
14 }
15 onerror() {
      local exit_code=$1
       shift
17
     local error_msg="$@"
18
19
      echo "ERROR: $error_msg" 1>&2
20
21
      exit "$exit_code"
22 }
23
24 size=5
25 byhour="cut -d ':' -f 1"
26 is_byhour=0
27 after=""
28
29 set_size() {
     [ "$1" -lt 1 ] && onerror 3 "size must be > 1"
30
     size=$1
31
32
33 set_byhour() {
      byhour="${byhour} | tr -s ' ' | cut -d ' ' -f 3"
      after=" | sort -k 2"
      is_byhour=1
37
    set_size 24
39 doit() {
   cmd="cat $0 | ${byhour} | sort | uniq -c | sort -nr | head -n ${
     size} ${after}"
41 case ${is_byhour} in
```

```
42
               printf "%-7.7s %-6.6s %-2.2s\n" "occurences" "date" "hour
43
               printf "%-17.17s\n" "----
44
45
      1)
46
              printf "%-7.7s %-2.2s\n" "occurences" "hour"
47
               printf "%-10.10s\n" "----
48
49
50
      esac
      eval "${cmd}"
51
52
53
54
   # [ $# -eq 0 ] && dohelp
55
   [ $# -eq 0 ] && echo "you need arguments" && dohelp
56
57
   while getopts "s:bh" opt
58
59
   do
     case $opt in
60
     h)
61
              dohelp
62
63
               ;;
64
     s)
             set_size "$OPTARG"
65
66
67
          b)
         set_byhour
68
69
         :)
70
71
               onerror 2 "$OPTARG needs a parameter"
72
    /?)
73
             onerror 7 "option $OPTARG is unknown"
74
75
              ;;
76
     esac
77
78
79
   shift $((OPTIND-1))
   doit "$@"
```

En fait **getopts** ne sait traiter que les *options courtes* et classiques d'**Unix**. Les *options longues* à la mode **Linux** ne sont pas supportées. L'avantage de **getopts** est son mode de fonctionnement assez simple. Son inconvénient principal est d'être très spécifique à *bash* même si **POSIX** le soutient, ce qui fait qu'il n'est pas forcément disponible partout.

Pour avoir les *options longues*, il faut utiliser l'outil **GNU** *getopt* (sans le *s* de fin) <sup>7</sup>. Je reste donc sur ma méthode qui n'est finalement ni meilleure ni pire.

- c.2.2.2. Avec **bash** . On peut profiter des avantages de bash (boucles, tableaux, ...) comme dans ce script (qui ne fonctionne **pas** avec sh):

```
#!/usr/bin/env bash
1
2
   scriptname="$(basename $0)"
   # set -e
5
   dohelp() {
       cat << DOHELP
   \{scriptname\} [-h|--help] : this text
  ${scriptname} [options] file file...: stats
10
   options:
       -s|--size N : number of most important hours, default 5
11
12
       -b|--byhour : for each hours
13
  DOHELP
       exit 0
14
15
16
17
18 byhour="cut -d ':'
  is_byhour=0
19
   after=""
20
  hours=
21
22
23
       [ "$1" -lt 1 ] && onerror 3 "size must be > 1"
24
25
       size=$1
26
   set_byhour() {
28
       byhour="${byhour} | tr -s ' ' | cut -d ' ' -f 3"
```

<sup>7.</sup> voir cette discussion sur StackOverflow

```
after=" | sort -k 2"
30
       is_byhour=1
31
       set_size 24
32
       for ((i=0; i<24; i++))</pre>
33
34
35
           hours[i]=0
36
       done
37
38
39
   doit() {
40
       cmd="cat 0 \mid LC_ALL=C \text{ tr } -cd ' \ln[:print:]' \mid \{byhour\} \mid sort
41
          | uniq -c | sort -nr | head -n ${size} ${after}"
42
       case ${is_byhour} in
           0)
43
                printf "%-7.7s %-6.6s %-2.2s\n" "occurences" "date" "hour
44
                printf "%-17.17s\n" "--
45
                eval "$cmd"
46
47
                ;;
           1)
48
                printf "%-7.7s %-2.2s\n" "occurences" "hour"
49
                printf "%-10.10s\n" "-----
50
                while read count index reste; do
51
                     local h=${index#0}
52
                     hours[h]=${count}
53
                done <<<"$(eval ${cmd})"</pre>
54
                for ((i=0; i<24; i++))</pre>
55
                do
56
                     printf "%7d %02d\n" ${hours[i]} $i
57
58
                done
                ;;
60
      esac
61
62
   [ $# -eq 0 ] && dohelp
63
64
65
   while [ $end -eq 0 ]
66
67
   case $1 in
68
```

```
69
             -h | --help)
70
                  dohelp
71
              -s|--size)
72
                  shift
73
74
                   [ $# -eq 0 ]
                                  && onerror 2
                  set_size "$1"
75
                  shift
76
77
                  ;;
78
             -b|--byhour)
79
                  shift
80
                  set_byhour
81
82
                  doit "$@"
83
84
                  ;;
85
   done
86
```

Conrairement aux précédents, si une tranche horaire n'est pas représentée dans les fichiers logs passés en paramètres, elle sera tout de même affichée avec la valeur 0.

# Quatrième partie -d. commandes utiles

#### - d.1. les noms de fichiers

Les commandes les plus utiles sont **dirname** et **basename** . La première renvoie le repertoire du nom fichier et la seconde renvoie simplement le nom de base comme ici :

```
$ which firefox
| /usr/local/bin/firefox|
| $ basename $ (which firefox)|
| firefox|
| $ dirname $ (which firefox)|
| 6 /usr/local/bin|
| $ $
```

On en profite pour présenter l'indispensable which qui donne le nom complet d'une application se trouvant dans le PATH.

### - d.2. cherche et remplace

Les outils de base sont **egrep**, **sed** et **tr** <sup>8</sup>. Ces trois outils utilisent les expressions régulières. Ces expressions régulières ressemblent fortement à ce que l'on trouve dans Perl, Python, Java et les autres. La différence fondamentale à ne pas oublier : les expressions régulières des outils **GNU** sont rapides, efficaces, les autres... beaucoup moins <sup>9</sup>.

Les expressions régulières méritent une formation complète car elles ne sont pas vraiment intuitives. De plus, les variations qui existent entre **POSIX**, **GNU**, **BSD**, les SHELLS qui en rajoutent parfois, sans compter que certains outils, certaines distributions n'ont pas leurs outils vraiment à jour (cf. **Redhat**).

- d.2.1. cherche. Pour la recherche, nous avons grep et egrep. En fait, la plupart du temps, egrep équivaut à grep -E permettant l'utilisation des expressions régulières dites étendues ou POSIX dont la documentation se trouve dans man 7 regex sous Debian.

<sup>8.</sup> L'outil awk, est, à mon humble avis, à reléguer dans les musées.

<sup>9.</sup> L'introduction du backtracking peut détruire complètement les performances